

Introduction à l'Apprentissage Automatique (Mineur semestre 7)
Année universitaire 2023-2024

TP Apprentissage Automatique

TP 1 : Régression linéaire

Vassilis.Christophides@ensea.fr
guillaume.renton@ensea.fr

Table des matières

1 Utiliser et configurer un environnement iPython **2**

1.1 À faire : . . . 2

1.2 À faire : . . . 2

1.3 À faire : . . . 2

2 Manipulation et visualisation des données **3**

2.1 À faire : . . . 3

2.2 À coder : . . . 3

2.3 À faire : . . . 3

2.4 À coder : . . . 4

3 Régression linéaire simple **4**

3.1 À coder : . . . 4

3.2 À coder : . . . 4

3.3 À coder : . . . 4

3.4 À coder : . . . 4

3.5 À coder : . . . 4

3.6 À coder : . . . 5

3.7 À coder : . . . 5

3.8 À coder : : . . . 5

3.9 À coder : . . . 5

Introduction

La régression linéaire est une famille d'algorithmes d'apprentissage automatique visant à ajuster un modèle linéaire à un ensemble de données. Les applications vont de la reconstruction de signaux à la description empirique. L'ensemble de données considéré a été produit par l'Organisation mondiale de la santé. Il regroupe l'évolution de 20 caractéristiques sur 15 ans et dans de nombreux pays. L'un des objectifs de ce TP est de manipuler ce jeu de données et d'essayer de prédire l'évolution de l'espérance de vie à travers différentes variables variables.

Objectifs :

- Utiliser et configurer un environnement iPython.
- Manipuler et visualiser un jeu des données reel.
- Construire une régression linéaire simple ou multivariable.
- Appliquer un modèle de régression linéaire sur un jeu des données reel.
- Évaluer la qualité de l'ajustement d'un modèle de régression linéaire via R^2.

Le notebook correspondant à ce TP est disponible sur Moodle. Répondez aux questions directement sur ce notebook. Le notebook doit être remis avant la prochaine session. Le travail peut être fait en binôme.

1 Utiliser et configurer un environnement iPython

1.1 À faire :

Exécuter les cellules suivantes :

```
a = 3
b = 4
c = a + b
```

```
c = c
```

```
print(c)
```

```
c
```

Question 1

Qu'est-ce qui déclenche l'affichage de la sortie ?

1.2 À faire :

Exécutez les cellules suivantes :

```
import shutil
import pkgutil

def show_acceptable_modules():
    line = '-' * 100
    print('{}\n{:^30}|{:^20}\n{}'.format(line, 'Module', 'Location', line))
    for entry in pkgutil.iter_modules():
        print('{:30}| {}'.format(entry[1], entry[0].path))
```

```
show_acceptable_modules()
```

Question 2

Qu'est-ce qui est affiché sur la dernière sortie ?
Quelle est la version de Python utilisée ?
Pour ce premier TP, vous aurez besoin de :

- pandas
- matplotlib
- numpy
- sklearn

Ces paquets sont-ils installés dans votre environnement ?

1.3 À faire :

Exécutez les cellules suivantes :

```
pandas.__version__
```

Question 3

Comment résoudriez-vous cette erreur ?

2 Manipulation et visualisation des données

2.1 À faire :

Si vous utilisez jupyter-notebook, exécutez les cellules suivantes :

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv("data/Life_Expectancy_Data.csv")
df = df.dropna()
df.info()
```

Pour les utilisateurs de colab, le code est un peu différent. La fonction upload() vous permet de naviguer dans votre gestionnaire de fichiers pour télécharger le fichier "Life_Expectancy_Data.csv".

```
import pandas as pd
import matplotlib.pyplot as plt
form google.colab import files
files.upload();

df = pd.read_csv("Life_Expectancy_Data.csv")
df = df.dropna()
df.info()
```

Question 4

Pouvez-vous expliquer les différents éléments imprimés sur la dernière sortie ?

```
df1 = df[(df.Country == "France") & (df.Year > 2010)]
print("df1: ", df1)
df2 = df[(df.Country == "France")].Year
print("df2: ", df2)
```

Question 5

Comment interpréter le nouveau DataFrame df1 par rapport à df ? Que représente df2 par rapport à df1 ?

2.2 À coder :

Dans quel intervalle de valeurs évolue l'espérance de vie en Belgique entre 2004 et 2008

2.3 À faire :

Calculer la corrélation entre toutes les caractéristiques

Question 6

Quelles sont les valeurs les plus prometteuses et les moins prometteuses à utiliser pour prédire l'espérance de vie ?

La fonction scatter de matplotlib permet de tracer deux valeurs l'une par rapport à l'autre. Voici la documentation de cette fonction.

2.4 À coder :

Tracez l'espérance de vie par rapport à l'une des valeurs que vous avez choisies.

3 Régression linéaire simple

```
1 import numpy as np
```

3.1 À coder :

Sélectionnez l'espérance de vie et la composition des revenus des ressources du Belarus, de Madagascar, de l'Inde et de la Lituanie. Ce nouveau cadre de données s'appellera df_study.

3.2 À coder :

Mettez en œuvre une fonction linéaire des moindres carrés et appliquez-la aux données sélectionnées précédemment.

3.3 À coder :

Sur la même figure, tracez la ligne correspondant au résultat précédent et les points de données correspondant à df_study

3.4 À coder :

Maintenant, implémentez une fonction de descente de gradient def gradDescent(x, y, theta, alpha, iters) où x sont les covariables, y la valeur cible, theta les poids initiaux, alpha le taux d'apprentissage et iters le nombre d'itérations de descente de gradient.

3.5 À coder :

Calculer la descente du gradient sur df_study pour 1000 itérations avec différentes valeurs de alpha. Vous pouvez initialiser theta avec theta_0 = 0 et theta_1 = 1.

3.6 À coder :

Sur la même figure, tracez l'évolution de theta_0 à travers les itérations pour chaque valeur différente d'alpha que vous avez choisie. Faites la même chose pour theta_1.

Question 7

Discutez du rôle d'alpha.

3.7 À coder :

Calculez le score R^2 pour la régression sur df_étude. Vous pouvez trouver une fonction sklearn here.

Question 8

La régression linéaire est-elle appropriée entre les deux variables sélectionnées ?

Question 9

Si ce n'est pas le cas, quelle serait la régression pertinente entre ces deux variables ?

4 Visualisation diagnostique

4.1 À coder :

Calculer l'erreur résiduelle de modèle et afficher le résiduel vs valeur prédite

Question 10

Que concluez vous à partir de l'affichage obtenu ?

4.2 À coder :

Faites de même avec l'affichage Scale Location.

Question 11

Que concluez vous à partir de l'affichage obtenu ?

4.3 À coder :

En utilisant une librairie annexe ou en le codant vous-même, affichez la distance de Cook correspondant à ces données

Question 12

Que concluez vous à partir de l'affichage obtenu ?

4.4 À coder :

Le traitement d'un trop grand nombre de variables peut parfois être contre-productif et il peut être plus intéressant de supprimer certaines caractéristiques. Une façon d'évaluer l'importance de chaque variable est de calculer le f_test dont la fonction est nommée f_regression in sklearn.

Question 13

D'après le f_test, quelles sont les variables les moins prometteuses ? Comparez-les avec la corrélation de votre sous-ensemble.